

ПРАВИТЕЛЬСТВО РОССИЙСКОЙ ФЕДЕРАЦИИ
ФГАОУ ВО НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ
«ВЫСШАЯ ШКОЛА ЭКОНОМИКИ»

Факультет компьютерных наук
Образовательная программа «Прикладная математика и информатика»

Отчет об исследовательском проекте на тему:
Анализ и визуализация данных с использованием Yandex
DataLens: исследование на основе персональных индикаторов
сердечно-сосудистых заболеваний

Выполнил:

студент группы БПМИ2414
Соколов Матвей Алексеевич

02.06.2026

(дата)

Принял руководитель проекта:

Иванов Андрей Александрович
Доцент
Базовая кафедра Т-Банка

Москва 2026

Аннотация

Исследовательский проект направлен на изучение взаимосвязей между личными показателями человека, такими как продолжительность сна или индекс массы тела, и наличием заболеваний сердечно-сосудистой системы среди нескольких наборов данных, построенных на основе результатов опросов Центров по контролю и профилактике заболеваний США. Целью проекта является исследование влияния персональных индикаторов на вероятность возникновения сердечно-сосудистых заболеваний и выявление групп населения, попадающих в зону риска с помощью визуализации и анализа данных. Большую часть проекта используется Python и Yandex DataLens.

В качестве результата исследовательского проекта предоставлен интерактивный дашборд, построенный в сервисе Yandex DataLens.

Ключевые слова: Yandex DataLens, сердечно-сосудистые заболевания, анализ данных, Python, визуализация, персональные индикаторы, дашборд.

Содержание

1	Основные термины и определения	4
2	Введение	6
2.1	Цель	6
2.2	Объект исследования	6
2.3	Предмет исследования	7
2.4	Методы исследования	7
2.5	Задачи	7
2.6	Актуальность работы	8
2.7	План работы	8
3	Описание наборов данных	10
3.1	Результаты опроса 2020 года	10
3.1.1	О числовых признаках в наборе данных	10
3.1.2	О булевых признаках в наборе данных	10
3.1.3	О категориальных признаках в наборе данных	11
3.2	Результаты опроса 2022 года	14
3.3	Предварительная обработка данных	17
4	Обзор академических источников	22
4.1	Использование набора данных в других исследованиях	22
4.2	Персональные индикаторы ССЗ в других исследованиях	23
5	Обучение моделей	24
5.1	Подготовка	24
5.2	Результаты обучения	25
6	Проектирование интерактивной визуализации	26
7	Заключение	28

7.1	Описание выполненных задач	28
7.2	Описание интерактивной визуализации	29
7.3	Ответ на основной вопрос работы	31
7.4	Ограничения работы	32
7.5	Развитие работы	33
8	Описание применения генеративной модели	34
A	Сертификат о прохождении курса	39

1 Основные термины и определения

- 1 **Сердечно-сосудистые заболевания (ССЗ)** — общее название заболеваний сердца и кровеносных сосудов [1].
- 2 **Всемирная организация здравоохранения (ВОЗ)** — одно из крупнейших специализированных учреждений системы ООН. Устав ВОЗ определяет основную цель Организации как достижение всеми народами наиболее высокого уровня здоровья и провозглашает ответственность правительств за состояние здоровья населения своих стран [2].
- 3 **ВМІ** — индекс массы тела. Величина, позволяющая оценить степень соответствия массы человека и его роста и тем самым косвенно судить о том, является ли масса недостаточной, нормальной или избыточной [3].
- 4 **Датасет** — набор собранных и упорядоченных данных, предназначенных для хранения, обработки и анализа [4].
- 5 **Behavioral Risk Factor Surveillance System (BRFSS)** — ведущая в стране система телефонных опросов по вопросам здоровья, в рамках которой собираются данные о жителях США, касающиеся их рискованного поведения в отношении здоровья, хронических заболеваний и использования профилактических услуг (по материалам [5]).
- 6 **Центры по контролю и профилактике заболеваний США (англ. Centers for Disease Control and Prevention, CDC)** — федеральное агентство министерства здравоохранения США, созданное в 1946 году для обеспечения охраны здоровья населения путем осуществления контроля за заболеваниями и принятия мер по их предотвращению [6].

- 7 **Дисбаланс (классов)** — проблема, которая возникает при обучении модели классификации на несбалансированных данных, когда один класс представлен значительно меньшим количеством примеров, чем другой класс [7].
- 8 **One-Hot Encoding** — метод преобразования категориальных данных в числовой формат, понятный алгоритмам машинного обучения [8].
- 9 **Гиперпараметр** — параметр машинного обучения, значение которого используется для управления процессом обучения. Его значение устанавливается перед началом обучения [9].
- 10 **Вайрфрейм** — схема с низким уровнем детализации, которая визуализирует структуру и содержание цифрового проекта [10].
- 11 **Feature importance** — технология, позволяющая определить, какие признаки вносят наибольший вклад в предсказательную способность модели [11].

2 Введение

На протяжении всей истории развития человечества люди сталкивались с заболеваниями сердца и сосудов. Ярким тому примером может послужить исследование Horus [13], где авторы изучают сердечно-сосудистую систему древнеегипетских мумий. Кальцификация артерий была найдена у 20 из 52 мумий, что свидетельствует о высоком распространении атеросклероза среди египтян того времени.

Удар болезни по жизненно важным органам может стать фатальным и в наши дни. Наука не стоит на месте, и современная медицина активно разрабатывает и совершенствует методы диагностики, профилактики и лечения ССЗ [14].

Заболевания сердечно-сосудистой системы являются основной причиной смерти по всему миру. Согласно оценкам ВОЗ, ежегодно от них погибает 19,8 млн человек [12].

Данная работа посвящена изучению и выявлению групп населения, которые являются наиболее уязвимыми к заболеваниям сердечно-сосудистой системы.

2.1 Цель

Исследование влияния персональных характеристик человека на вероятность возникновения сердечно-сосудистых заболеваний и выявление групп населения, которые демонстрируют наиболее высокий риск.

2.2 Объект исследования

К объекту исследования автор относит население США, результаты опроса которого представлены в наборе данных [18], предоставленным центром по контролю и профилактике заболеваний.

2.3 Предмет исследования

Результаты опроса населения США за 2020 и 2022 года исследуются на предмет выявления ключевых факторов риска сердечно-сосудистых заболеваний.

2.4 Методы исследования

- Программирование на языке Python, с использованием библиотек: `pandas`, `polars`, `matplotlib`.
- Предобработка и подготовка данных с использованием библиотеки `polars`.
- Визуализация данных с использованием Yandex DataLens и Datawrapper.
- Обзор академических источников.

2.5 Задачи

Задачи проекта разделяются на две части: исследовательскую и программную.

Исследовательская часть:

- Исследовать набор данных из [18] и провести его описательный анализ.
- Провести обзор источников, использующих рассматриваемый набор данных.
- Использовать дополнительные наборы данных для расширения контекста исследования.
- Оценить влияние персональных индикаторов на риск возникновения ССЗ с помощью моделей машинного обучения.

- Продемонстрировать результаты исследования с помощью интерактивного дашборда.

Программная часть:

- Подготовить имеющиеся наборы данных для дальнейшего анализа с помощью языка программирования Python и библиотек `polars`, `matplotlib`, `seaborn`.
- Пройти подготовительный онлайн-курс «DataLens: анализ и визуализация данных» от Yandex Cloud.
- Подготовить макет дашборда с помощью сервиса `draw.io`.
- Обучить модели машинного обучения с помощью библиотек `sklearn` и `catboost`.
- Реализовать интерактивный дашборд на базе платформы Yandex DataLens.

2.6 Актуальность работы

Несмотря на усилия современной медицины, направленные на противостояние заболеваниям сердца и сосудов, они остаются ведущей причиной смертности во всем мире. Использование современных методов анализа данных и визуализаций может помочь в борьбе с ССЗ, выявляя скрытые закономерности между персональными характеристиками людей и риском возникновения подобных заболеваний. Таким образом, можно считать, что актуальность работы продемонстрирована.

2.7 План работы

В Таблице [2.1](#) представлен план работы над проектом.

Задача	Дата начала	Дата окончания
Составить описательный анализ	15.11.25	28.12.25
Составить обзор академ. источников	15.11.25	11.01.26
Предварительно обработать данные	15.11.25	10.02.26
Построить вайрфрейм	11.01.26	04.02.26
Построить диаграмму Ганта	11.01.26	04.02.26
Пройти подготовительный курс	11.01.26	10.02.26
Подготовить работу к сдаче КТ1	24.01.26	04.02.26
Провести эксперименты с моделями	04.02.26	01.04.26
Оформить GitHub репозиторий	04.02.26	01.05.26
Построить дашборд	01.04.26	01.05.26
Дописать заключение	01.05.26	21.05.26
Подготовить презентацию	01.05.26	01.06.26

Таблица 2.1: План работы.

На Рисунке 2.1 представлена диаграмма Ганта, соответствующая плану работы.




Рис. 2.1: Диаграмма Ганта.

3 Описание наборов данных

Наборы данных представляют собой результаты опроса более 400 тыс. взрослых, проводимого в рамках системы наблюдения за поведенческими факторами риска (BRFSS). Опросы проводились Центрами по контролю и профилактике заболеваний США (CDC) в 2020 и 2022 годах.

3.1 Результаты опроса 2020 года

Набор данных содержит 18 колонок, среди которых можно выделить следующие типы: числовые, булевы и категориальные.

3.1.1 О числовых признаках в наборе данных

Набор данных содержит 4 числовых признака:

- **BMI** — индекс массы тела;
- **PhysicalHealth** — количество дней за последние 30, в которые человек чувствовал физические недомогания;
- **MentalHealth** — количество дней за последние 30, в которые человек чувствовал психологические недомогания;
- **SleepTime** — количество часов сна.

3.1.2 О булевых признаках в наборе данных

В наборе данных представлены 9 булевых признаков:

- **HeartDisease** — наличие ССЗ, а именно ишемической болезни сердца или инфаркта миокарда;
- **Smoking** — курение;

- **Asthma** — наличие астмы;
- **AlcoholDrinking** — употребление алкоголя;
- **Stroke** — перенос инсульта ранее;
- **DiffWalking** — трудности с ходьбой;
- **PhysicalActivity** — физическая активность;
- **SkinCancer** — наличие рака кожи;
- **KidneyDisease** — наличие болезней почек.

3.1.3 О категориальных признаках в наборе данных

Набор данных предоставляет 5 категориальных признаков:

- **Sex** — пол (Male/Female);
- **Race** — раса (White/Black/Hispanic/Asian/Other);
- **Diabetic** — наличие диабета (Yes/No/No, borderline diabetes);
- **GenHealth** — общее самочувствие (Excellent/Very good/Good/Fair/Poor);
- **AgeCategory** — возраст. 10 категорий по 5 лет каждая (кроме последней) от 18-24 до 80 or older.

Набор данных не содержит отсутствующих значений. В Таблице [3.1](#) представлен его фрагмент.

HeartDisease	BMI	Smoking	AlcoholDrinking	Stroke	PhysicalHealth	MentalHealth	DiffWalking	Sex	AgeCategory	Race	Diabetic	...
No	16.60	Yes	No	No	3.0	30.0	No	Female	55-59	White	Yes	...
No	20.34	No	No	Yes	0.0	0.0	No	Female	80 or older	White	No	...
No	26.58	Yes	No	No	20.0	30.0	No	Male	65-69	White	Yes	...
No	24.21	No	No	No	0.0	0.0	No	Female	75-79	White	No	...
No	23.71	No	No	No	28.0	0.0	Yes	Female	40-44	White	No	...
Yes	28.87	Yes	No	No	6.0	0.0	Yes	Female	75-79	Black	No	...
No	21.63	No	No	No	15.0	0.0	No	Female	70-74	White	No	...
No	31.64	Yes	No	No	5.0	0.0	Yes	Female	80 or older	White	Yes	...
No	26.45	No	No	No	0.0	0.0	No	Female	80 or older	White	No	...
No	40.69	No	No	No	0.0	0.0	Yes	Male	65-69	White	No	...

Таблица 3.1: Фрагмент результатов опроса из [18] за 2020 год.

State	Sex	GeneralHealth	PhysicalHealthDays	MentalHealthDays	LastCheckupTime	PhysicalActivities	SleepHours	RemovedTeeth	...
Alabama	Female	Very good	4.0	0.0	Within past year...	Yes	9.0	None of them	...
Alabama	Male	Very good	0.0	0.0	Within past year...	Yes	6.0	None of them	...
Alabama	Male	Very good	0.0	0.0	Within past year...	No	8.0	6 or more, but not all	...
Alabama	Female	Fair	5.0	0.0	Within past year...	Yes	9.0	None of them	...
Alabama	Female	Good	3.0	15.0	Within past year...	Yes	5.0	1 to 5	...
Alabama	Male	Good	0.0	0.0	Within past year...	Yes	7.0	None of them	...
Alabama	Female	Good	3.0	0.0	Within past year...	Yes	8.0	6 or more, but not all	...
Alabama	Male	Fair	5.0	0.0	Within past year...	Yes	8.0	1 to 5	...
Alabama	Male	Good	2.0	0.0	5 or more years ago	No	6.0	None of them	...
Alabama	Female	Very good	0.0	0.0	Within past year...	Yes	7.0	None of them	...

Таблица 3.2: Фрагмент результатов опроса из [18] за 2022 год.

В качестве примера рассматривается один из признаков в наборе данных до его предобработки, а именно возрастная категория респондента. Так как сердечно-сосудистые заболевания чаще встречаются у пожилых людей [19], перед дальнейшим анализом стоит рассмотреть, как меняется доля больных ССЗ в разных возрастных группах.



Рис. 3.1: Процентное соотношение больных ССЗ участников [18] за 2020 год по возрастным категориям. Вероятность заболевания растёт с возрастом.

На Рисунке 3.1 видно, что доля людей с ССЗ постепенно увеличивается с возрастом. В младших возрастных категориях процент больных небольшой, но начиная со средних и старших возрастных групп он заметно растёт. Самая большая доля больных наблюдается в группе 80 or older. График показывает ожидаемую зависимость: возраст связан с наличием ССЗ, поэтому признак AgeCategory можно считать одним из важных для дальнейшего анализа и построения моделей.

3.2 Результаты опроса 2022 года

Для 2022 года представлены два набора данных: один содержит только полные строки данных без отсутствующих значений (уже очищенный авторами набора данных), а во втором они встречаются. Наборы данных имеют 246 022 и 445 132 строки соответственно. По сравнению с набором для 2020 года количество параметров в этих наборах в 2 раза больше — 40 шт.. Разница в размерах данных значительна, поэтому в дальнейшем работа будет производиться с неочищенным набором данных. В Таблице 3.2 представлен его фрагмент.

На Рисунке 3.2 представлена диаграмма количества пропущенных значений в каждом признаке

Появились такие колонки, как: State (штат, в котором проживает участник опроса), наличия различных заболеваний (HadAngina, HadDepressiveDisorder, и т.д.), RemovedTeeth (количество удалённых зубов), вакцинации за последние 12 месяцев и др.

Помимо американских штатов, в колонке State присутствуют записи для Гуама, Пуэрто-Рико и Виргинских Островов (территории не входящие в состав США но принадлежащие им). На территориях Американского Самоа и Северных Марианских островов BRFSS не проводится [5], поэтому для этих территорий данные в наборе отсутствуют.

На Рисунке 3.3 представлено распределение участников по штатам в неочищенном наборе данных 2022 года. Диаграмма построена с помощью сервиса Datawrapper.




Рис. 3.2: График количества пропущенных значений в каждом столбце-признаке набора 2022 года. Для некоторых признаков, как, например, TetanusLast10Tdap, отсутствует почти треть данных.




Рис. 3.3: Распределение участников опроса из [18] по штатам за 2022 год (неочищенный). Наибольшее количество опрошенных из Вашингтона.

3.3 Предварительная обработка данных

Для дальнейшей работы наборы данных подлежат обработке. Поскольку в наборе за 2020 год всего 18 признаков, большая часть которых является категориальными, появление одинаковых записей нельзя относить к аномалиям. Это может объяснить их большое количество — 18 078 шт. В наборе данных 2022 года их количество меньше и составляет 157, поскольку количество признаков, в том числе числовых, стало больше.

Далее, для удобства работы с набором в Yandex DataLens автор бинаризует булевы колонки, которые принимают значения «Yes» или «No», заменяя их на 1 и 0, соответственно.

Для удаления выбросов набора 2020 года анализируются ящики с усами, построенные с помощью библиотеки `matplotlib` :




Рис. 3.4: Ящики с усами для числовых признаков из [18], набор данных 2020 года. Статистически значимая выборка лежит в пределах от примерно 15 до 42 пунктов для BMI, от 0 до 5 для PhysicalHealth, от 0 до 7 для Mental Health и от 3 до 11 для SleepTime.

На Рисунке 3.4 видно, что в некоторых колонках присутствуют неправдоподобные значения: например, некоторые участники опроса заявляли что спят более 12 или менее 3 часов в сутки. Так как таких записей несущественное количество, они подлежат удалению. Аналогично с индексом массы тела. Некоторые участники отмечали, что их значение ИМТ составляет более 60 пунктов. Согласно формуле ИМТ

$$\text{BMI} = \frac{m}{h^2}, \quad (1)$$

где m — масса тела в килограммах, а h — рост в метрах, при среднем росте американца 175 см [20] его вес составит 183 кг, поэтому такие высокие ИМТ тоже обозначаются как выбросы и удаляются. Таким же образом удаляются и записи с ИМТ менее 15.

Признаки PhysicalHealth и MentalHealth не используются для удаления выбросов. Эти записи — ответы участников на вопросы "Сколько дней из последних 30 Вы чувствовали физическое/психологическое недомогание?". Логично, что пожилые люди или люди с депрессией могли дать высокие показатели, и выбросом это не является.

Аналогичные ящики с усами были построены и для набора 2022 года и изображены на Рисунке 3.5.

Помимо удаления выбросов аналогично набору 2020 года, в наборе 2022 года были оставлены только записи с ростом в диапазоне от 1.4 до 2.2 метров и весом от 40 до 160 килограммов.

В наборе 2022 года присутствуют и другие аномальные строки. Например, некоторые респонденты-мужчины отмечали наличие беременности в колонке HadDiabetes. Другие же неверно указывали рост, вес и ИМТ — разница между указанным ИМТ и ИМТ, рассчитанным по формуле 1, превышала 1 пункт. Таких записей 351 шт.

Аналогичная набору 2020 года целевая переменная HeartDisease от-




Рис. 3.5: Ящики с усами для числовых признаков из [18], набор данных 2022 года. По сравнению с 2020 годом, верхний ус стал выше у признаков PhysicalHealthDays и MentalHealthDays, т.е. недомогания респондентов участились. График SleepHours и BMI практически не изменился. Статистически значимая выборка WeightInKilograms и HeightInMeters лежит в пределах от примерно 30 до 135 и 1.42 до 2.00 соответственно.

существует в наборе 2022 года, поэтому её нужно добавить самостоятельно. Для этого достаточно объединить булевы столбцы HadHeartAttack и HadAngina. Стоит уточнить, что здесь Angina обозначает *Angina pectoris* или, в переводе на русский язык, стенокардию, которая является одним из симптомов вышеупомянутой ишемической болезни сердца. Значит, если хотя бы один из признаков положителен, HeartDisease также должен принимать положительное значение. Записи, в которых отсутствуют значения одновременно для HadHeartAttack и HadAngina, удаляются. Таких записей 5 021 шт.

Также стоит отметить, что многие признаки этих датасетов эквивалентны между собой, но имеют разные названия: например, DiffWalking и

DifficultyWalking, SleepTime и SleepHours, и т.д.. Другие же признаки различаются своей подробностью: например, если для набора данных 2020 года признак Smoking являлся бинарным (содержал только ответы «Yes»/«No»), признак SmokerStatus для 2022 года принимает значения

- Current smoker — now smokes every day;
- Current smoker — now smokes some days;
- Former smoker;
- Never smoked;
- пропуск (null).

Прочие признаки имеют эквивалентные по смыслу значения: так, например, элементы AgeCategory набора 2020 года имеют вид "18-24 в то время как элементы набора 2022 года — "Age 18 to 24".

Результаты обработки данных представлены в Таблице 3.3 и Таблице 3.4 соответственно.

Шаг	Задача	До	После	Удалено	Процент
0	Изначальный размер	319 795	319 795	0	0.00%
1	Бинаризация признаков	319 795	319 795	0	0.00%
2	Удаление выбросов	319 795	316 696	3 099	0.97%
3	Удаление аномальных данных	316 696	316 696	0	0.00%
4	Переименование признаков	316 696	316 696	0	0.00%
Итого		319 795	316 696	3 099	0.97%

Таблица 3.3: Изменение набора данных 2020 года в процессе предварительной обработки в строках.

Также для будущей работы с моделями автор создает набор `df_merged`, объединяя предобработанные наборы с помощью `polars.concat`. В полученном наборе сохранены общие признаки, которые совпадают с признаками набора 2020 года. Таким образом, мы увеличили обучающую выборку будущих моделей. Полученный набор содержит 698 247 записей.

Шаг	Задача	До	После	Удалено	Процент
0	Изначальный размер	445 132	445 132	0	0.00%
1	Бинаризация признаков	445 132	445 132	0	0.00%
2	Создание целевой переменной	445 132	445 132	0	0.00%
3	Удаление строк без HeartDisease	445 132	440 111	5 021	1.13%
4	Удаление выбросов	440 111	381 902	58 209	13.23%
5	Удаление аномальных данных	381 902	381 551	351	0.09%
6	Бинаризация статуса курения	381 551	381 551	0	0.00%
7	Переименование значений	381 551	381 551	0	0.00%
Итого		445 132	381 551	63 581	14.28%

Таблица 3.4: Изменение набора данных 2022 года в процессе предварительной обработки в строках.

После обработки данных в полученных наборах наблюдается существенный дисбаланс целевой переменной (см. Рис. 3.6), работа над которым описана в следующих главах.




Рис. 3.6: Распределение целевой переменной для обоих наборов данных. Наблюдается сильный дисбаланс, который в дальнейшем может усложнить обучение моделей.

4 Обзор академических источников

4.1 Использование набора данных в других исследованиях

Рассматриваемый в работе источник данных используется в различных исследованиях, в частности, в работах [15, 16].

В работе [15] автор использует набор данных за 2020 год для обучения модели, которая должна помочь в диагностике сердечно-сосудистых заболеваний на основе персональной информации. Автор отмечает, что набор данных не сбалансирован и требует использования специальных методов для устранения дисбаланса классов: здоровых людей гораздо больше, чем тех, кто имеет ССЗ. Автор предполагает, что использование более комплексных методов балансировки может повысить точность его модели. Стоит отметить, что автор использует технику преппроцессинга One-Hot Encoding для конвертации категориальных данных в числовые.

Этот же набор используется в работе [16]. В ней автор строит визуализации каждого параметра по отдельности, ищет корреляции между ними, проводит статистические тесты и обучает несколько моделей. По результатам работы автор предлагает рекомендации по улучшению образа жизни, которые значительно снизят риск возникновения сердечно-сосудистых заболеваний в дальнейшем, такие как

- здоровое питание;
- отказ от курения, алкоголя и наркотических веществ;
- контроль холестерина в крови и др..

Автор отмечает, что по результатам визуализаций употребление алкоголя и курение не являются основными факторами развития ССЗ, что достаточно неочевидно. Как и в предыдущем исследовании, автор упоминает

дисбаланс в данных и предлагает оставить подбор лучших гиперпараметров моделей для соревнований.

4.2 Персональные индикаторы ССЗ в других исследованиях

В работе [17] авторы проводят анонимный опрос RADICAL среди 4149 человек в возрасте от 40 до 69 лет. Опрос включает в себя 23 вопроса об образе жизни, таких как недостаток овощей и фруктов в рационе, и наличии факторов риска, таких как курение, диабет, ожирение, сон продолжительностью менее 7 часов и т.д.. Также в набор данных включены анализы крови участников на различные виды холестерина и показатели артериального давления. Результаты опроса можно интерпретировать как персональные индикаторы. Исследование показывает, что почти 90% участников имеют хотя бы один фактор риска, при этом вероятность наличия таких факторов у женщин выше, чем у мужчин. Кроме того, исследование показывает высокую распространённость факторов риска ССЗ. Авторы отмечают, что цифровые инструменты, такие как подобные опросы, оказываются полезными в профилактике сердечно-сосудистых заболеваний.

5 Обучение моделей

В данном разделе проводятся несколько экспериментов с различными моделями бинарной классификации, такими как

- `CatBoostClassifier`
- `LogisticRegression`
- `RandomForestClassifier`

Ключевой целью является вывод `feature importance` лучшей модели. Данные экспериментов опубликуется на дашборде.

5.1 Подготовка

Во время предобработки данных для `CatBoostClassifier` возникли технические сложности с библиотекой `polars`: невозможность корректно перевести категориальные данные в числовые, при этом эта ошибка до сих пор не решена [21]. В дальнейшем принято решение использовать `pandas`.

Для работы с несбалансированными классами `CatBoostClassifier` позволяет автоматически рассчитать подходящие веса, поэтому другая предобработка данных для этой модели не требуется. Более того, эта модель доступна «из коробки», и отдельного пайплайна не требует.

При обучении модели логистической регрессии необходимо заполнить пропущенные значения. Поскольку точность данных важна, а количество пропусков в некоторых колонках достигает практически трети всех значений, такие пропуски будут заполнены медианным значением столбца, но также получат метку о том, что настоящее значение отсутствует. Таким образом, модель, не принимающая пропуски, всё равно о них знает. Поскольку логистическая регрессия не поддерживает категориальные данные, они

переводятся в числовые с помощью one-hot энкодинга. Также модель требует нормализации числовых данных. Итоговый пайплайн обучения состоит из `OneHotEncoder`, `SimpleImputer` и `StandardScaler`. Для набора 2020 года `SimpleImputer` не нужен, поскольку данные не содержат пропусков. За автоматическую работу с дисбалансом классов в модели отвечает гиперпараметр `class_weight='balanced'`.

Модель `RandomForestClassifier` является ансамблем деревьев, поэтому нормализация признаков ей не требуется. Однако она также не работает с пропусками и категориями, поэтому в пайплайне остаются `StandardScaler` и `SimpleImputer`.

5.2 Результаты обучения

Итоговые модели предсказывают целевую переменную `HeartDisease` на наборах 2020, 2022 года и на наборе с объединёнными данными. Качество полученных моделей по метрикам указано в Таблице 5.1.

Набор данных	Модель	ROC-AUC	Balanced Accuracy
2020	CatBoostClassifier	0.8433	0.7664
2022	CatBoostClassifier	0.8534	0.7765
merged	CatBoostClassifier	0.8374	0.7595
2020	LogisticRegression	0.8395	0.7636
2022	LogisticRegression	0.8512	0.7755
merged	LogisticRegression	0.8328	0.7548
2020	RandomForestClassifier	0.8393	0.7627
2022	RandomForestClassifier	0.8478	0.7699
merged	RandomForestClassifier	0.8351	0.7575

Таблица 5.1: Сравнение качества моделей классификации. На всех наборах данных [18] лучшей моделью по метрике Balanced Accuracy является `CatBoostClassifier`.

Программный код обучения моделей находится в репозитории GitHub [22]. Также были сохранены feature importance лучших моделей.

6 Проектирование интерактивной визуализации

Перед реализацией дашборда в сервисе DataLens необходимо построить его вайрфрейм. Для этого автор использует сервис draw.io, позволяющий строить диаграммы различной сложности прямо в браузере.

Первая страница (Рис. 6.1) содержит распределения признаков, а также краткую сводку о целевой переменной. С помощью селекторов можно выделить конкретную возрастную группу и/или штат.




Рис. 6.1: Страница вайрфрейма 1.

На второй странице (Рис. 6.2) находятся визуализации зависимостей целевой переменной от персональных характеристик респондентов. Особое внимание требуется уделить лучшим признакам по мнению модели с третьей страницы.

На третьей странице (Рис. 6.3) находятся данные экспериментов с моделями машинного обучения. В верхней части указана статистика модели, показавшей лучший результат. Ниже находится таблица прошедших экспериментов с селекторами конкретной модели и/или набора данных.




Рис. 6.2: Страница вайрфрейма 2.




Рис. 6.3: Страница вайрфрейма 3.

На последней странице (Рис. 6.4) указаны использованные наборы данных и ссылка на репозиторий GitHub.

Использованные наборы данных:

- Набор 1 (ссылка)
- Набор 2 (ссылка)
- Набор 3 (ссылка)

Репозиторий GitHub (ссылка)

Дашборд выполнен в рамках курсовой работы студентом 2 курса НИУ ВШЭ ФКН

Рис. 6.4: Страница вайрфрейма 4.

7 Заключение

В ходе выполнения работы были проанализированы результаты опроса населения США. Результатом работы стал GitHub репозиторий [22], содержащий программный код предобработки, визуализаций и обучения моделей, и дашборд [23], демонстрирующий ключевые факторы риска возникновения сердечно-сосудистых заболеваний.

7.1 Описание выполненных задач

Во время написания работы автором были решены следующие задачи:

- Составлен описательный анализ исследуемых наборов данных. Было рассмотрено их содержание, типы признаков, пропуски, выбросы и аномальные значения в Главе 3.
- Проведён обзор источников, использующих эти наборы данных, а также источников, изучающие персональные индикаторы ССЗ в Главе 4.
- Проведена обработка исходных наборов данных. В ходе работы были бинаризованы булевы признаки, обработаны аномальные значения и выбросы, переименованы колонки наборов и создан новый набор

данных, дающий больше данных для обучения моделей в Параграфе [3.3](#).

- Обучены модели `CatBoostClassifier`, `LogisticRegression` и `RandomForestClassifier` на каждом из наборов данных, проведено их сравнение по качеству и отобраны лучшие по метрике `Balanced Accuracy` в Главе [5](#).
- Пройден курс «DataLens: анализ и визуализация данных», сертификат которого находится в Приложении [A](#).
- Разработан вайрфрейм дашборда в Главе [6](#), а также реализован сам интерактивный дашборд [\[23\]](#).
- Оформлен GitHub репозиторий [\[22\]](#), содержащий программный код предобработки данных, их визуализации и обучения моделей. Сам репозиторий и его структура подробно описаны в README-файле.

7.2 Описание интерактивной визуализации

В этом параграфе описан полученный дашборд, доступный по ссылке [\[23\]](#).

В верхней части первой страницы дашборда, изображённой на Рисунке [7.1](#) находится информация о полученном путём объединения новом наборе данных. Он содержит 698 247 записей, среди которых 61 761 относится к людям с ССЗ. Общая доля больных составляет 8,85%. Круговая диаграмма справа дополнительно демонстрирует дисбаланс целевой переменной. В центре находятся распределения числовых признаков, которые можно выбирать, нажав на нужный признак в верхней части графика. Нижняя часть содержит тепловую карту распределения участников опроса 2022 года по штатам. Для лучшего восприятия рядом находится таблица с точными значениями. Также на странице присутствует селектор возраста, позво-

ляющий узнать существующие распределения для конкретной возрастной группы.




Рис. 7.1: Первая страница дашборда [23]. Содержит базовые данные наборов, такие как распределения, количество респондентов, тепловую карту.

На второй странице, изображённой на Рисунке 7.2 визуализированы зависимости самых распространённых и важных признаков, таких как ИМТ, возраст, пол, вредные привычки. При этом, стоит отметить, что процент больных ССЗ среди тех, кто употребляет алкоголь ниже.

На третьей странице описаны результаты экспериментов с моделями. В верхней части, изображённой на Рисунке 7.3, находятся главные метрики качества, самые важные признаки, которые отобрали модели и полные таблицы feature importance. Неожиданно, но результаты работы [16] подтверждаются — лишь модель 2020 года внесла курение в топ важных признаков. Употребление алкоголя также не вошло в число наиболее значимых признаков.

В нижней части страницы, изображённой на Рисунке 7.4, находится подробная статистика проведённых экспериментов.



Рис. 7.2: На второй странице дашборда визуализированы зависимости самых распространённых и важных признаков.



Рис. 7.3: Верхняя часть третьей страницы дашборда, содержащая метрики и feature importance лучших моделей.

7.3 Ответ на основной вопрос работы

Основной целью исследования являлось выявление факторов риска и выявление групп людей, подверженных сердечно-сосудистым заболеваниям.

Статистика экспериментов						
Модель Нет выбранных значений		Набор данных Нет выбранных значений				
Набор данных	Модель	Balanced Accuracy	ROC-AUC	PR-AUC	Мера F1	
merged	CatBoostClassifier	0.760	0.837	0.842	0.342	0.344
merged	RandomForestClassifier	0.757	0.835	0.839	0.339	0.353
merged	LogisticRegression	0.755	0.833	0.840	0.340	0.348
2022	CatBoostClassifier	0.776	0.853	0.884	0.384	0.367
2022	LogisticRegression	0.776	0.851	0.880	0.380	0.373
2022	RandomForestClassifier	0.770	0.848	0.864	0.364	0.377
2020	CatBoostClassifier	0.766	0.843	0.851	0.351	0.342
2020	LogisticRegression	0.764	0.839	0.842	0.342	0.347
2020	RandomForestClassifier	0.763	0.839	0.836	0.336	0.356

Рис. 7.4: Нижняя часть третьей страницы дашборда, содержащая статистику проведённых экспериментов.

ям.

Основным фактором риска оказался возраст, что подтверждает визуализация 3.1 и высокая важность признака AgeCategory у моделей. Также важными характеристиками оказались

- пол — мужчины более подвержены сердечно-сосудистым заболеваниям;
- ИМТ — ожирение увеличивает риск заболевания;
- общее самочувствие — логично, недомогания могут сигнализировать о проблемах со здоровьем;
- наличие диабета;

При этом, вредные привычки, такие как курение или употребление алкоголя оказались не такими существенными, как ожидалось. Полезные привычки, как физическая активность, также не вошли в число наиболее значимых признаков. Выводы подтверждает полученный дашборд [23] и результаты обучения моделей.

7.4 Ограничения работы

Главным ограничением работы автор считает субъективность ответов респондентов. Такие данные могут быть неточными, поскольку участники опроса указывали их самостоятельно. Решением проблемы могло бы стать

подключение аналога электронной медкарты и анонимизированный сбор параметров пациентов.

Другим ограничением является существенное различие между наборами данных, а также отсутствие целевой переменной в наборе 2022 года. В качестве решения этой проблемы построена переменная HeartDisease на основе HadHeartAttack и HadAngina, однако такой способ восстановления не гарантирует полной точности и может быть ошибочен, что повлияет на результаты моделей и выводы исследования.

Наконец, в данных наблюдается существенный дисбаланс классов, отчего качество распознавания классов хуже, а предобработка сложнее.

7.5 Развитие работы

Работу можно улучшить, например

- расширить и актуализировать наборы данных. Исследование проходит на данных респондентов за 2020 и 2022 год. Расширение выборки респондентов, проведение опроса в других странах и увеличение количества вопросов позволило бы обучить модели точнее и выявить новые факторы риска, а добавление актуальных на данный момент данных позволило бы анализировать динамику факторов во времени.
- провести большее количество экспериментов и подобрать оптимальные гиперпараметры. Это позволило бы выбрать лучшие по качеству модели, а выбор других типов моделей позволил бы изучить данные под другим углом;
- расширить дашборд, что позволило бы удобнее и шире интерпретировать полученные результаты исследования, а подключение к системе опросов позволило бы следить за обновлениями результатов в реальном времени.

8 Описание применения генеративной модели

В ходе исследования генеративная модель была использована исключительно в качестве инструмента для работы с вёрсткой файлов $\text{\LaTeX}$ и Markdown, упрощая такие действия, как оформление Таблиц и Рисунков.

Список литературы

1. Сердечно-сосудистые заболевания. — Текст : электронный // Википедия : [сайт]. — URL: https://ru.wikipedia.org/wiki/Сердечно-сосудистые_заболевания (дата обращения: 15.11.2025).
2. Всемирная организация здравоохранения (ВОЗ) (справка). — Текст : электронный // Министерство иностранных дел Российской Федерации : [сайт]. — URL: https://www.mid.ru/ru/foreign_policy/un/organizatsii_sistemy_oon/1946338/ (дата обращения: 23.01.2026).
3. Индекс массы тела. — Текст : электронный // Википедия : [сайт]. — URL: https://ru.wikipedia.org/wiki/Индекс_массы_тела (дата обращения: 27.12.2025).
4. Датасеты: что это, виды и как использовать для анализа данных. — Текст : электронный // ProductStar : [сайт]. — URL: <https://productstar.ru/blog/datasety-cto-eto-vidy-i-kak-ispolzovat-dlya-analiza-dannykh> (дата обращения: 28.12.2025).
5. Behavioral Risk Factor Surveillance System. — Текст : электронный // cdc.gov : [сайт]. — URL: <https://www.cdc.gov/brfss/index.html> (дата обращения: 31.12.2025).
6. Центры по контролю и профилактике заболеваний США. — Текст : электронный // Википедия : [сайт]. — URL: https://ru.wikipedia.org/wiki/Центры_по_контролю_и_профилактике_заболеваний_США (дата обращения: 04.01.2026).
7. Демидова, Л. А. Методы решения проблемы дисбаланса классов в задаче бинарной классификации / Л. А. Демидова, М. А. Шаршатов, А. А.

- Шыхыев. — Текст : непосредственный // ИТ-Стандарт. — 2023. — № 1. — С. 22-33.
8. One-hot encoding: что это такое и как применять в машинном обучении. — Текст : электронный // sky.pro : [сайт]. — URL: <https://sky.pro/wiki/analytics/one-hot-encoding-что-это-такое-и-как-применять-в-машинном-обучении/> (дата обращения: 28.12.2025).
 9. Гиперпараметр. — Текст : электронный // Википедия : [сайт]. — URL: <https://ru.wikipedia.org/wiki/Гиперпараметр> (дата обращения: 28.12.2025).
 10. Что такое вайрфреймы в дизайне: правила создания Wireframe, преимущества и недостатки. — Текст : электронный // Блог Яндекс Практикума : [сайт]. — URL: <https://practicum.yandex.ru/blog/что-такое-vajrfrejmy/> (дата обращения: 13.01.2026).
 11. Sklearn Feature Importance – метод оценки значимости признаков. — Текст : электронный // sky.pro : [сайт]. — URL: <https://sky.pro/wiki/analytics/sklearn-feature-importance-метод-оценки-значимости-признаков/> (дата обращения: 24.05.2026).
 12. Сердечно-сосудистые заболевания. — Текст : электронный // Всемирная организация здравоохранения (ВОЗ) : [сайт]. — URL: <https://www.who.int/ru/health-topics/cardiovascular-diseases> (дата обращения: 23.01.2026).
 13. Allam A. H. et al. Atherosclerosis in ancient Egyptian mummies: the Horus study // JACC: Cardiovascular Imaging. – 2011. – Т. 4. – №. 4. – С. 315-327.
 14. Спирина И. В. и др. Инновационные методы лечения сердечно-сосудистых заболеваний: обзор последних достижений в хирургии, фармакотерапии и лечении через изменение образа жизни // Вестник Санкт-

- Петербургского университета. Медицина. – 2025. – Т. 20. – №. 1. – С. 44-59.
15. Wang Heart Disease Classification Based on Personal Indicators / Wang, Xuanye. —, 2022. — 8 с. — Текст : непосредственный.
 16. Zubkov, Georgy Heart Disease. Exploratory data analysis. / Georgy Zubkov. — Текст : электронный // Kaggle : [сайт]. — URL: <https://www.kaggle.com/code/georgyzubkov/heart-disease-exploratory-data-analysis/notebook> (дата обращения: 28.12.2025)..
 17. A digital tool for self-reporting cardiovascular risk factors: The RADICAL study / F. S. José, Castela Inês, G. M. Sara [и др.]. — Текст : непосредственный // International Journal of Cardiology Cardiovascular Risk and Prevention. — 2025. — № 24.
 18. Personal Key Indicators of Heart Disease. — Текст : электронный // Kaggle : [сайт]. — URL: <https://www.kaggle.com/datasets/kamilpytlak/personal-key-indicators-of-heart-disease/data> (дата обращения: 31.12.2025).
 19. Гериатрия. — Текст : электронный // mededtech.ru : [сайт]. — URL: <https://library.mededtech.ru/rest/documents/ISBN9785970450932> (дата обращения: 24.05.2026).
 20. Average Height Around the World. — Текст : электронный // thebonescience.com : [сайт]. — URL: <https://thebonescience.com/blogs/journal/average-height-around-the-world> (дата обращения: 24.05.2026).
 21. <https://github.com/pola-rs/polars/issues/17585>. — Текст : электронный // github.com : [сайт]. — URL: <https://github.com/pola-rs/polars/issues/17585> (дата обращения: 02.06.2026).

22. cvd-analysis. — Текст : электронный // GitHub : [сайт]. — URL: <https://github.com/j0pl0p/cvd-analysis> (дата обращения: 02.06.2026).
23. Дашборд исследования. — Текст : электронный // Yandex DataLens : [сайт]. — URL: <https://datalens.yandex/lw4awrvaz70с6> (дата обращения: 02.06.2026).

А Сертификат о прохождении курса




Рис. А.1: Сертификат, подтверждающий успешное прохождение курса «DataLens: анализ и визуализация данных».