

Анализ и визуализация данных с использованием Yandex DataLens: исследование на основе персональных индикаторов сердечно-сосудистых заболеваний

исследовательский проект
выполнил Соколов М. А., БПМИ2414
принял Иванов А. А., доцент, базовая кафедра Т-Банка

Актуальность проекта

ССЗ

основная причина смертности
в мире

Около

19,8 млн

человек умерло от сердечно-
сосудистых заболеваний
согласно оценкам ВОЗ на 2022 г.

Динамика заболеваемости ССЗ




Рис. 1. Динамика заболеваемости сердечно-сосудистыми заболеваниями в целом, артериальной гипертензией, цереброваскулярными болезнями и ишемической болезнью сердца, по материалам из [1].





Цель проекта

Исследование влияния персональных характеристик на вероятность возникновения ССЗ и выявление групп повышенного риска

Предмет исследования

Результаты опроса населения США за 2020 и 2022 года исследуются на предмет выявления ключевых факторов риска сердечно-сосудистых заболеваний.

Задачи проекта



Обзор академических источников

Heart Disease Classification Based on Personal Indicators

Xuanye Wang

Используется набор данных 2020 года

Автор обучает модели, отмечая дисбаланс классов и необходимость обработки категориальных признаков

Heart Disease. Exploratory data analysis

Georgy Zubkov

Используется набор данных 2020 года

Автор демонстрирует распределения признаков, корреляции, статистические тесты, обучение моделей и даёт рекомендации для профилактики ССЗ

A digital tool for self-reporting cardiovascular risk factors: The RADICAL study

José Ferreira Santos, Inês Castela и др.

Используется собственный набор данных, основанный на анонимном опросе о факторах риска ССЗ

Авторы показывают, что цифровые опросы могут быть полезны для выявления групп риска





Пайплайн предобработки данных



Обучение моделей

Таблица 1. Результаты экспериментов моделей по метрике Balanced Accuracy. Целевой переменной является параметр HeartDisease.

Набор данных	Модель	Balanced Accuracy
2020	CatBoostClassifier	0.7664
2020	LogisticRegression	0.7636
2020	RandomForestClassifier	0.7626
2022	CatBoostClassifier	0.7764
2022	LogisticRegression	0.7755
2022	RandomForestClassifier	0.7698
merged	CatBoostClassifier	0.7595
merged	LogisticRegression	0.7547
merged	RandomForestClassifier	0.7574


На всех наборах данных лучшее качество показал CatBoostClassifier. При этом другие метрики, такие как F1-score, ROC-AUC, PR-AUC и др. также оказались наилучшими у этой модели классификации.



Подготовка дашборда

Перед построением дашборда был разработан вайрфрейм, демонстрирующий примерное представление макета будущих визуализаций

Дашборд исследования




О наборе данных

Использованные наборы данных:

- Набор 1 (ссылка)
- Набор 2 (ссылка)
- Набор 3 (ссылка)

Репозиторий GitHub (ссылка)

Дашборд выполнен в рамках курсовой работы студентом 2 курса НИУ ВШЭ ФКиН



демонстрация интерактивного дашборда





Результаты исследования

Ответ на основной вопрос работы

- Основным фактором, связанным с сердечно-сосудистыми заболеваниями стал **возраст**.
- Также важными признаками стали пол, ИМТ, общее самочувствие и наличие диабета.
- Вредные привычки не вошли в число главных признаков модели и не показали ожидаемого результата.
- Это подтверждается результатами моделей машинного обучения и визуализациями, а также академическими источниками.

Доля респондентов с ССЗ по возрастным категориям, набор 2020 года




Рис. 2. Визуализация зависимости доли больных ССЗ от возрастной группы. Процент больных ССЗ растёт с возрастом рассматриваемой группы.





Ограничения и развитие работы

Ограничения:

- **Субъективность данных:** самостоятельные ответы могут быть неточными
- **Отсутствие целевой переменной:** набор 2022 года не содержит признак HeartDisease напрямую, а его восстановление по другим признакам может содержать ошибки
- **Структура данных:** дисбаланс классов и пропуски в данных усложняют обучение и интерпретацию

Пути развития:

- **Расширение данных:** можно добавить страны, а также больше данных других лет для анализа динамики
- **Улучшение моделей машинного обучения:** подбор гиперпараметров моделей, а также расширение самого набора моделей
- **Развитие интерактивного дашборда:** добавление новых чартов и подключение обновляемых источников данных





Итоговый дашборд проекта



GitHub-репозиторий проекта
с сертификатом о прохождении курса по
Yandex DataLens





Используемые источники

1. Бичурин Д.Р. СЕРДЕЧНО-СОСУДИСТЫЕ ЗАБОЛЕВАНИЯ. РЕГИОНАЛЬНЫЙ АСПЕКТ / Д.Р. Бичурин, О.В. Атмайкина, О.А. Черепанова // Международный научно-исследовательский журнал. – 2023. – №8 (134). – URL: <https://research-journal.org/archive/8-134-2023august-undefined/10.23670/IRJ.2023.134.103> (дата обращения: 12.06.2026). – DOI: 10.23670/IRJ.2023.134.103. – EDN: JMQBSO
2. Wang Heart Disease Classification Based on Personal Indicators / Wang, Xuanye. –, 2022. – 8 с. – Текст : непосредственный.
3. Zubkov, Georgy Heart Disease. Exploratory data analysis. / Georgy Zubkov. – Текст : электронный // Kaggle : [сайт]. – URL: <https://www.kaggle.com/code/georgyzubkov/heart-disease-exploratory-data-analysis/notebook> (дата обращения: 28.12.2025)..
4. A digital tool for self-reporting cardiovascular risk factors: The RADICAL study / F. S. José, Castela Inês, G. M. Sara [и др.]. – Текст : непосредственный // International Journal of Cardiology Cardiovascular Risk and Prevention. – 2025. – № 24.

и другие (18 шт.).



Ящики с усами для числовых признаков, набор данных 2022 года




Рис А. Пример анализа выбросов на основе усиковых диаграмм

Кол-во пропущенных значений у каждого признака в наборе данных 2022 года




Рис Б. Визуализация кол-ва пропущенных значений



ОКН

